

### HELSINGIN YLIOPISTO — HELSINGFORS UNIVERSITET — UNIVERSITY OF HELSINKI

Tiedekunta — Fakultet — Faculty		Laitos — Institution -	— Department				
Makamantii 1		Tiotoionleäsitt-1-	rtiotoon leiter				
Matemaattis-luonnontieteellinen  Tekijä — Författare — Author	Tietojenkäsittelytieteen laitos						
Olli Rissanen							
Työn nimi — Arbetets titel — Title							
Tietokantakyselyjen optimointi relaatiotietokannassa  Oppiaine — Läroämne — Subject							
Tietojenkäsittelytiede							
Työn laji — Arbetets art — Level Kandidaatintutkielma	Aika — Datum — Mo		Sivumäärä — Sidoantal - 21	— Number of pages			
Tiivistelmä — Referat — Abstract	14. huhtikuuta 2013		21				
Tutkielmassa tutustutaan tietokantakyselyjen optimointiin relaatiotietokantojen hallin-							
tajärjestelmien osalta sekä o	optimoinnin vaiku	tukseen kyselyjen	suorituskyvyssä.				
eajarjostomien osarea sena e	sponnommir vama	ivaniscon nysonyjon	saomasiy vyssa.				
Avainsanat — Nyckelord — Keywords  Information systems — Overy optimization							
Information systems Query optimization Säilytyspaikka — Förvaringsställe — Where deposited							
Muita tietoja — Övriga uppgifter — Additiona	al information						

# Sisältö

1	Joh	danto	3
2	Tau	staluku	5
	2.1	Relaatiomalli	5
	2.2	Optimoijan tavoitteet	5
	2.3	Optimoijan historia	6
3	Tiet	tokantakyselyn prosessointi	7
	3.1	Kyselyn jäsentäminen	7
	3.2	Kyselyn optimointi	9
	3.3	Kyselyn suorittaminen	9
4	Opt	imoijan toiminta	10
	4.1	Hakualueen läpikäynti	10
		4.1.1 Dynaamiset algoritmit	10
		4.1.2 Muut algoritmit	11
	4.2	Kyselysuunnitelmien tuottaminen	11
		4.2.1 Join-operation toteutustavat	12
	4.3	Kyselysuunnitelmien kustannusarviointi	14
		4.3.1 Systeemitaulustoon tallennettu tilastotieto	15
		4.3.2 Tulosjoukon koon arviointi	15
5	Alil	kyselyt	<b>17</b>
6	Yht	seenveto	18
Lŧ	ihtee	rt	19

### 1 Johdanto

Modernit järjestelmät lisäävät jatkuvasti tietokantojen työtaakkaa tiedon määrän kasvaessa. Jotta tiedosta saadaan mahdollisimman paljon irti, tarvitaan tiedon hallitsemiseen yhä tehokkaampia työkaluja. Tietokannan suorituskyky on tärkeää koko järjestelmän suorituskyvyn osalta, sillä tiedon lukeminen massamuistista on hidasta verrattuna rekistereiden tai välimuistin käyttöön. Optimoimalla tietokantakyselyjen suoritusta voidaan vaikuttaa suoritettujen operaatioiden määrään sekä muistialueen kokoon ja siten vähentää tietokannan vasteaikaa sekä resurssien käyttöä. [MKR12]

Tietokantaa käytetään tietokannan hallintajärjestelmällä, joka on kokoelma ohjelmia tiedon tallentamiseen, muokkaamiseen, analysoimiseen ja
keräämiseen tietokannasta. Hallintajärjestelmää käytetään kyselykielellä,
joista esimerkiksi SQL [CAE+76] on suunniteltu relaatiotietokantojen hallintajärjestelmille. Hallintajärjestelmän vastuulla on kyselyn muuttaminen
tietokannan ymmärtämään muotoon säilyttäen kyselyn alkuperäisen tarkoituksen. Kyselyn optimointi on toteutettu automaattisena toimenpiteenä
hallintojärjestelmän sisältämässä kyselyn optimoijassa, ja kaikista hallintajärjestelmän komponenteista optimoijalla on suurin merkitys tietokannan
suorituskykyyn. [MKR12] Kyselyn optimoijan tavoitteena on minimoida itse
optimointiin käytetty aika ja maksimoida optimoinnista saatu hyöty. [JK84]

Optimoija toimii arvioimalla mahdolliset menetelmät kyselyn suorittamiseen ja valitsemalla niistä tehokkaimman. [SAC<sup>+</sup>79] Menetelmää kyselyn suorittamiseksi sanotaan kyselysuunnitelmaksi, ja se sisältää sarjan algebrallisia operaatioita tietokannan relaatioille jotka tuottavat tulokseksi halutun vastauksen. Tietokantakyselyä vastaavia kyselysuunnitelmia voi olla useita, sillä kysely voidaan usein esittää monena algebrallisesti toisiaan vastaavana esityksenä. [JK84] Algebrallista operaatiota kohden voi myös löytyä usei-

ta toteutuksia, kuten join-operaatiota toteuttavat merge join, hash join ja nested loop join. Kyselysuunnitelma sisältää operaatioiden lisäksi tiedon ne toteuttavista algoritmeista. Saman kyselyn sisältämät mahdolliset kyselysuunnitelmat voivat olla suorituskyvyltään jopa eri suuruusluokassa. [Ioa96, Ora13]

Tutkielmassa keskitymme kyselyn optimoijan toimintaan ja ongelmiin yleisellä tasolla. Jokainen kaupallinen optimoija on osittain erilainen kokonaisuus komponentteja, jotka kuitenkin pohjautuvat samoihin yleisiin malleihin. Yksittäistä hallintajärjestelmää käsiteltäessä mainitaan siitä erikseen. Tutkielman tavoitteena on tutustuttaa lukija optimoijan toiminnan perusteisiin ja optimoijan ajankohtaisiin ongelmiin.

Optimointi on vaikea hakuongelma, jossa hakualue voi nousta erittäin suureksi. Haasteeksi nousee kyselysuunnitelmien hakeminen ja niiden suorituskyvyn ennustaminen. Kaikkien mahdollisten kyselysuunnitelmien arvioiminen on usein liian hidasta, joten optimoijan tulee valita pienin mahdollinen hakualue joka pitää sisällään halvimmat suunnitelmat. [Cha98] Suorituskyvyn ennustamisen ja hakualueen rajauksen lisäksi optimoija tarvitsee tehokkaan algoritmin koko hakualueen läpikäymiseen. On epärealistista odottaa kyselyn optimoijan aina löytävän parhaan kyselysuunnitelman, ja onkin tärkeämpää välttää huonoimpia suunnitelmia ja löytää hyvä suunnitelma. [RG03]

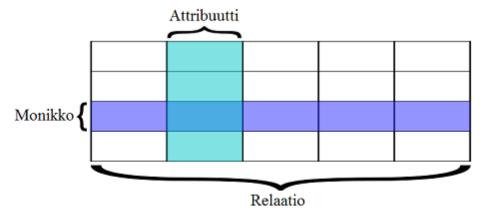
Kappale 2 sisältää esitiedot kyselyn optimoijan toiminnalle, jonka lisäksi kappaleessa perehdytään optimoijan historiaan. Kappale 3 tiivistää tietokantakyselyn prosessoinnin hallintajärjestelmän sisällä ja esittelee optimoijan toiminnan pääpiirteittäin kyselyn prosessoinnissa. Optimoijan toimintaan tarkemmin syvennytään kappaleessa 4, jossa käsitellään kyselysuunnitelman luomista, kustannusarviointia ja parhaan kyselysuunnitelman valintaa. Kyselyn sisältämien alikyselyjen prosessointi käydään läpi kappaleessa 5.

### 2 Taustaluku

#### 2.1 Relaatiomalli

Relaatiotietokanta on relaatiomalliin [Cod70] perustuva tietokanta. Relaatiomallin keskeinen piirre on kaiken datan esittäminen n-paikkaisen karteesisen tulon osajoukkona, ja se tarjoaa deklaratiivisen menetelmän datan ja kyselyjen määrittämiseen. Relaatiomalli koostuu attribuuteista, monikoista ja relaatioista. Matemaattisessa määritelmässä attribuutti on pari joka sisältää attribuutin nimen ja tyypin sekä jokaiseen attribuuttiin liittyy sen arvojoukko. Monikko on järjestetty joukko attribuuttien arvoja. Relaatio koostuu otsakkeesta ja sisällöstä, jossa otsake on joukko attribuutteja ja keho on joukko monikkoja. Relaation otsake on myös jokaisen monikon otsake. Visuaalisessa esityksissä relaatio on taulukko ja monikko taulukon rivi.

Kuva 1: Relaatiomalliin perustuva tietokanta



### 2.2 Optimoijan tavoitteet

Tietokantakyselyjen optimoinnilla viitataan tietokantakyselyn suorittamiseen mahdollisimman tehokkaasti. Optimoinnin tavoitteena on joko maksimoida suorituskyky annetuilla resursseilla tai minimodia resurssien käyttö. Jarke ja

Koch määrittelivät artikkelissaan [JK84] mitattaviksi resursseiksi suorittimen ja muistin käytön sekä kommunikointikustannukset. Teorey ja Fry [TF82] huomasivat optimoijan vaikuttavan suorittimen palveluaikaan (service time), suorittimen jonotusaikaan, I/O:n palveluaikaan, I/O:n jonotusaikaan ja lukittumisen viiveeseen.

Muistin käyttö jakautuu tallennuskustannukseen sekä ulkomuistiin pääsyn kustannukseen. Tallennuskustannuksella tarkoitetaan ulkomuistin sekä puskurimuistin käyttöä, ja se tulee aiheelliseksi kun muistin käyttö aiheutuu pullonkaulaksi. Kommunikointikustannukset käsittävät tiedon viennin tallennuspaikasta laskentapaikkaan ja edelleen tulosten esityspaikkaan. Ne jakautuvat kommunikaatioväylän käyttökustannukseen ja tiedonsiirrosta aiheutuvaan suorittamisen viiveeseen.

Resurssin merkitys riippuu tietokantatyypistä. Jarke ja Koch erittelivät hajautetuissa tietokannoissa kommunikointikustannukset hallitseviksi kustannuksiksi, kun taas paikallisesti hajautetuissa tietokannoissa kaikilla resursseilla on sama painoarvo. Jarken ja Kochin mukaan keskitetyissä tietokannoissa ulkomuistiin pääsyn kustannus ja prosessorin käyttö ovat oleellisia. Tässä tutkielmassa keskitymme erityisesti keskitettyjen tietokantojen optimointiin.

### 2.3 Optimoijan historia

Kun Coddin relaatiomallin pohjalle luotiin sitä toteuttavia kieliä, nousi vuonna 1974 kehitetty SQL nopeasti käytetyimmäksi. SQL:n myötä optimoinnista tuli osa järjestelmän toiminnallisuutta, sillä SQL tarjosi deklaratiivisuutensa vuoksi useita tapoja toteuttaa kukin kysely. Ennen relaatiomallin käyttöä optimointi tehtiin käsin. Selinger et al. esittelivät artikkelissaan [SAC+79] System R-tietokantaohjelmiston OPTIMIZER-komponentin, joka on ensimmäisiä relaatiomalliin pohjautuvia kyselyn optimoijia. OPTI-

MIZER esittely dynaamisen hakualgoritmin kyselysuunnitelmien luomiseen, ja se on käytössä hieman muunneltuna käytännössä kaikissa kaupallisissa järjestelmissä. [Ioa96]

### 3 Tietokantakyselyn prosessointi

Tietokannan hallintajärjestelmän suorittama SQL-kyselyn prosessointi sisältää useita vaiheita. Kuva 2 esittää kyselyn optimointikerroksen ja suorituskerroksen hallintajärjestelmän sisällä. Alempana analysoimme komponenttien toimintaa tarkemmin.

Kyselyn jäsentäjä

Jäsennetty kysely

Kyselyn optimoija

Kyselysuunnitelman kustannusarvioija

Kyselysuunnitelman kustannusarvioija

Kyselysuunnitelman kustannusarvioija

Kuva 2: Kyselyn jäsentäminen, optimointi ja suoritus

### 3.1 Kyselyn jäsentäminen

Kyselyn prosessointi alkaa kyselyn jäsentäjän suorittamalla kyselyn syntaksin validoinnilla. [SAC+79] Osa hallintajärjestelmistä, kuten Oracle 11g, validoi myös samalla semantiikan oikeellisuuden. [Ora09] Syntaksin validoinnissa

jäsentäjä tarkastaa kyselyn lauseopin oikeellisuuden. Semantiikan validoinnissa tarkastetaan objektien aitous, kyselyn yksiselitteisyys, oikeus haettavaan tietoon ja muuttujien tyypin sopivuus sarakkeiden tyyppeihin. Useat hallintajärjestelmät myös tallentavat kyselyt validoinnin jälkeen talteen, jotta samaa kyselyä ei tarvitse jäsentää ja optimoida uudelleen. Yksi esimerkki kyselyjä tallentavasta hallintajärjestelmästä on Oracle Database, jossa tallennuspaikkaa kutsutaan nimellä Shared Pool. [Ora05]

Seuraavaksi jäsentäjä jakaa kyselyn lohkoihin(block) siten, että yhdessä lohkossa on täsmälleen yksi SELECT-lause, yksi FROM-lause ja korkeintaan yksi WHERE-, GROUP BY- ja HAVING-lause. [RG03] Kyselyn mahdollisesti sisältämät alikyselyt muodostavat kukin oman lohkonsa. Alikyselyitä tarkastellaan kappaleessa 5.

Jokainen lohko jäsennetään puuksi, joka on kyselyn algebrallinen esitysmuoto. [MJ12] Puun solmu sisältää yhden operaation kyselyn suorittamiseksi, ja sillä on nolla tai useampi alisolmua joiden ulostuloa(output) käytetään sen syötteenä. Esimerkiksi join-operaatiossa solmulla on kaksi alisolmua, joille toteutetaan join-operaatio ja sort-operaatiolla on yksi alisolmu joka järjestetään. Lehtisolmut ovat solmuja jotka suorittavat hakuja (scan) levyltä ja palauttavat saadut tulokset. Puu suoritetaan lehtisolmuista juureen.

Tämän jälkeen monimutkaiset kyselyt uudelleenkirjoitetaan (rewrite) soveltamalla niihin muutossääntöjä [Ioa96]. Pirahesh et al tutkivat uudelleenkirjotusta Starburst-hallintajärjestelmän osalta artikkelissa [PHH92], ja määrittivät uudelleenkirjoituksen tavoitteiksi tehdä kyselyistä mahdollisimman deklaratiivisia ja suorittaa luonnollisia heuristiikkoja, kuten predikaattien siirtämistä mahdollisimman aikaiseen vaiheeseen.

### 3.2 Kyselyn optimointi

Kun kysely on jäsennetty ja mahdollisesti uudelleenkirjoitettu, lähetetään se kyselyn optimoijalle. Kyselyn optimoija hakee tietokannan systeemitaulustoon tallennettua tilastotietoa kyselyyn liittyvistä relaatioista ja relaatioihin liittyvistä saantipoluista. Tilastotietoa käytetään kyselyn suorituskyvyn arviointiin. Saantipolku on menetelmä jolla taulurivit haetaan taulusta, ja se koostuu joko tiedoston lukemisesta tai indeksistä ja siihen liittyvistä valinnoista. Selinger et. al. tutkivat kattavasti saantipolkujen kustannusarviointia artikkelissaan [SAC+79].

Mikäli kyselyn semantiikkaa ei ole vielä tarkastettu, tarkastaa optimoija kyselyn semantiikan oikeellisuuden ja kyselyn tyyppien sopivuuden sarakkeisiin ja operaatioihin systeemitaulun tiedon pohjalta. (Selvennä tästä kappaleen loppuun) Optimoija määrittää lohkojen suoritusjärjestyksen ja prosessoi jokaisen lohkon FROM-lauseeseen liittyvät relaatiot. Mikäli lohkossa on useampi relaatio, arvioi optimoija join-operaation permutaatioiden suorituskyvyt ja valitsee tehokkaimman algoritmin operaation suorittamiseen. Optimoija valitsee jokaiselle lohkolle tehokkaimman saantipolun ja rakentaa niistä kyselysuunnitelman. [SAC+79] (koko kappaleen viite, korjaa)

### 3.3 Kyselyn suorittaminen

Seuraavassa vaiheessa kysely suoritetaan käyttämällä optimoijan tuottamaa kyselysuunnitelmaa. Suorittamisessa kyselysuunnitelma muutetaan suoritettavaksi konekieleksi ja kyselyn lähteen mukaan joko suoritetaan tai tallennetaan muistiin myöhempää suorittamista varten.

### 4 Optimoijan toiminta

Kyselyn optimoijan tulee hakea mahdolliset kyselysuunnitelmat ja arvioida niiden kustannus. Kappale on jaettu kolmeen osa-alueeseen, joista aluksi perehdymme hakualueen läpikäymiseen ja siihen käytettäviin yleisiin algoritmeihin. Tämän jälkeen tutkimme kyselysuunnitelman tuottamista esimerkin avulla, ja lopetamme kappaleen kyselysuunnitelmien kustannusarviointiin.

### 4.1 Hakualueen läpikäynti

Kyselysuunnitelmat sisältävä hakualue voi kasvaa erittäin suureksi kyselyn ollessa laaja. Optimoija käyttää heuristiikkoja pienentääkseen hakualueen kokoa, kuten keskittymällä vain vasemmalta syviin puihin. Optimoija voi näin karsia tarkasteltavia kyselysuunnitelmia merkittävästi. Tavoitteena on pitää hakualue mahdollisimman pienenä, sisältäen kuitenkin optimaalisen suunnitelman. [JK84] Kappaleessa tutustutaan Selinger et al esittelemään dynaamiseen algoritmiin [SAC+79] sekä vaihtoehtoisiin algoritmeihin hakualueen läpikäymiseen, kuten sääntöihin perustuvaan Starburst-hallintajärjestelmälle kehitettyyn algoritmiin [Loh88].

#### 4.1.1 Dynaamiset algoritmit

Selinger et al. System R:lle esittelemä algoritmi on dynaaminen karsiva ja tyhjentävä (exhaustive) hakualgoritmi. Dynaamista algoritmia pidetään standardina algoritmina optimoijalle, ja usean hallintajärjestelmän hakualgoritmi pohjautuu dynaamiseen algoritmiin sisältäen kuitenkin hieman variaatioita. Algoritmi rakentaa kaikki mahdolliset join-puut ja karsii alioptimaalisiksi tiedetyt puut.

#### 4.1.2 Muut algoritmit

Dynaamisia algoritmeja on kritisoitu tästä ja tästä [ähän?]...

#### 4.2 Kyselysuunnitelmien tuottaminen

Kyselysuunnitelma koostuu laajennetusta relaatioalgebrapuusta, jossa jokainen solmu kuvaa algebrallista operaatiota. Solmuun on liitetty tieto käytettävästä hakumetodista tiedon hakemiseen taulusta ja suoritusmetodista relaatio-operaation suoritukseen. Tutkitaan seuraavaa SQL-kyselyä:

SELECT K.nimi

FROM Kirjat K, Teokset T

WHERE K.tid = T.tid AND K.kid = 5 AND T.arvosana > 3

Kysely voidaan tulkita relaatioalgebrassa seuraavasti:

 $\pi_{nimi}(\sigma_{kid=5 \land arvosana>3}(Kirjat \bowtie_{tid=tid} Teokset))$ 


Kysely voidaan suorittaa esimerkiksi käyttäen join-operaatiossa nested loop join-algoritmia, jonka jälkeen jokaiselle riville suoritetaan valinta ja projektio. Kyselyä vastaava esimerkkikyselysuunnitelma esitetään kuvassa 3.

Join-operaatiossa voidaan käyttää hyväksi putkitusta (pipelining) [DSRS01], jossa operandi putkitetaan suorituksen aikana toiseen operaatioon ilman väliaikaista taulua tuloksen tallentamiseen, "lennossa". Ilman putkitusta väliaikaiset tulokset tulee materialisoida. Putkitusta käytetään usein peräkkäisten join-operaatioiden toteuttamiseen, jolloin jokainen operaation palauttama operandi voidaan syöttää seuraavan operaation parametriksi. Putkitusta voidaan käyttää operaation suorittavan algoritmin salliessa sen.

Usein tehokkaampi tapa kyselyn suorittamiseen on suorittaa valinnat mahdollisimman aikaisessa vaiheessa. [RG03] Esimerkkikyselyssä tauluille suorite-

11

Kuva 3: Kyselysuunnitelma erimerkkikyselylle




taan kullekin valinta erikseen, joten suorittamalla ne ennen join-operaatiota voidaan vähentää yhdistettävien alkioiden määrää. Tehokkaampi kyselysuunnitelma aikaisilla valinnoilla, tallentaen valinnat väliaikaismuuttujiin T1 ja T2, esitetään kuvassa 4.

Edelleen tehokkaampi tapa olisi väliaikaisen muuttujan käytön sijaan putkittaa valinta-operaatiosta alkiot suoraan join-operaatioon. Valinnan suorittaminen mahdollisimman aikaisin ei kuitenkaan aina tuota suoritusky-kyisintä tulosta. [RG03] Mikäli taulut on indeksoitu, voi valinta kadottaa tärkeät indeksit jolloin join-operaation suorittaminen hidastuu. Paras kysely-suunnitelma riippuu siten täysin taulujen koosta ja niiden indeksoinnista.

#### 4.2.1 Join-operation toteutustavat

Optimoija voi suorittaa usean peräkkäisen join-operaation liittämisen monella eri tavalla. Ono ja Lohman tutkivat join-operaation suorittamisjärjestysten

Kuva 4: Toinen kyselysuunnitelma erimerkkikyselylle




vaikutusta tarkemmin artikkelissaan [OL90], ja huomasivat join-operaation järjestyksen olevan hallitseva kustannus kyselyn optimoinnissa.

Tutkitaan kyselyä  $Kirjat \bowtie Teokset \bowtie Kirjailijat \bowtie Maat$ . Vasemmalta syväksi (left-deep) puuksi kutsutaan tapaa liittää kyselyt seuraavasti: ((( $Kirjat \bowtie Teokset$ )  $\bowtie Kirjailijat$ )  $\bowtie Maat$ ), jossa oikea lapsi on aina kantataulu. Optimoijat käyttävät usein pelkästään vasemmalta syviä puita, sillä eri tapoja liittää join-operaatioita on join-operaatioiden määrän kasvaessa erittäin paljon. Käyttämällä vain vasemmalta syviä puita voidaan pienentää hakualuetta merkittävästi. [?]left-deeppejä tutkiva artikkeli) Toinen syy on vasemmalta syvien puiden mahdollistama putkitus. Oikea lapsisolmu eli join-operaation sisempi taulu täytyy aina materialisoida, sillä se täytyy käydä läpi jokaiselle ulomman taulun eli vasemman lapsisolmun monikolle. [RG03] Kuva 5 havainnollistaa vasemmalta syvät ja lehtevät puut.

Ionaddis tutki artikkelissaan [IK91] left-deep puiden ja lehtevien (bushy) puiden suorituskykyeroja, ja huomasi lehtevien puiden optimoinnin olevan

Kuva 5: Vasemmalta syvät ja lehtevät puut



helpompaa ja sen tuottavan parempia tuloksia.

### 4.3 Kyselysuunnitelmien kustannusarviointi

(todo: siisti tämä alku)

Kustannusarviointi koostuu kahdesta vaiheesta: ensiksi arvioidaan jäsennetyn puun jokaisen alkion operaation suorittamiseen kuluva aika. Tämän jälkeen arvioidaan jokaisen alkion tulosjoukon koko, sekä tarkastetaan onko tulosjoukko järjestetty. Solmun tulosjoukko on ylisolmun syöte, joten sen koko ja järjestys vaikuttavat suoraan ylisolmun arviointiin.

Kyselysuunnitelman kustannus on sen sisältämien operaatioiden kustannusten summa. Yksittäisten operaatioiden kustannus arvioidaan käyttämällä systeemitaulustoon tallennettua tilastotietoa operaation relaatioihin liittyvistä tiedoista, kuten järjestyksestä ja koosta. Kappaleessa 4.3.1 tutustutaan tarkemmin systeemitaulustoon, ja kappaleessa 4.3.2 käsitellään tilastotiedon pohjalta tehtävää kyselysuunnitelman kustannusarviointia.

4.3.1 Systeemitaulustoon tallennettu tilastotieto

Systeemitaulusto sisältää tietokannan tilastollisen profiilin. Mannino et al.

tutkivat kattavasti tilastotiedon käyttöä kyselyn optimoinnissa artikkelissaan

[MCS88]. Mannino et al. mukaan tarkka tilastotiedon tallentaminen on

tärkeää kyselyn optimoinnille, mutta liian täsmällinen tallentaminen aiheutuu

rasitteeksi.

Mannino et al. jakoivat tilastollisen profiilin neljään kategoriaan: (1)

keskitietoihin kuten moodi, mediaani ja keskiarvo, (2) hajontaan kuten

varianssi sekä pienin ja suurin arvo, (3) kokoon kuten mahtavuus ja eri

arvojen lukumäärä sekä (4) frekvenssin jakaantumiseen kuten normaalius

ja tasaisuus. Systeemitaulusto sisältää myös jokaisesta taulusta tiedot sen

nimestä ja tiedoston nimestä, attribuuttien tyypeistä ja nimistä, indekseistä

ja niiden nimistä ja hakuavaimista, sekä yleisistä tiedoista kuten sivukoosta

ja puskurimuistin koosta.

todo: content

4.3.2 Tulosjoukon koon arviointi

Operaation kustannus riippuu syötteen koosta. Tutkitaan seuraavaa tapausta:

SELECT attribuuttit

FROM relaatiot

WHERE ehto  $1 \land$  ehto  $2 \land ... \land$  ehto n

Kyselyn palauttamien monikkojen maksimimäärä on relaatioiden karteesinen

tulo. Jokainen WHERE-ehto harventaa monikkojen määrää. WHERE-ehdon

vaikutusta tulosjoukon kokoon voidaan mallintaa lisäämällä jokaiseen ehtoon

vähennyskerroin, joka on oletettu suhde lähtöjoukosta tulosjoukkoon vain

15

kyseisen ehdon osalta. Tulosjoukon koko voidaan siten arvioida kertomalla maksimijoukko vähennyskertoimien tulolla. [RG03]

WHERE-lauseen ehtojen kertoimia voidaan laskea hyödyntämällä systeemitaulustoon tallennettua tilastotietoa. Mikäli relaatiolle ei ole tilastotietoa saatavilla, oletetaan relaation olevan pieni ja käytetään määriteltyä vakiota lasketun kertoimen sijaan. [SAC<sup>+</sup>79] Oletetaan seuraavat tiedot:

NKeys(I) = eri avainten lukumäärä indeksissä IF = vähennyskerroin

sarake=arvo

tyyppiselle ehdolle vähennyskerroin voidaan arvioida kaavalla  $F = \frac{1}{NKeys(I)}$ , jos sarakkeessa on indeksi kyseiselle relaatiolle. [SAC+79] Ilman indeksiä kyselyn optimoija käyttää kiinteää arvoa vähennyskertoimen arvioimiseen, joka esimerkiksi System R-relaatiotietokantaohjelmassa on 1/10.

sarake1 = sarake2

tapauksessa voidaan vähennyskerroin arvioida kaavalla  $F=\frac{1}{MAX(NKeys(I1),NKeys(I2))}$ jos kummassakin sarakkeessa on indeksi. Lisäksi oletetaan, että jokaisesta pienemmän indeksin arvoa vastaa arvo toisesta indeksistä. Mikäli vain toisessa sarakkeessa on indeksi, voidaan kustannus laskea aiemmalla kaavalla käyttäen indeksin omaavaa saraketta. Mikäli kummassakaan sarakkeessa ei ole indeksiä, arvioidaan arvoksi 1/10.

sarake > arvo

tapauksessa voidaan käyttää kaavaa  $F = \frac{suurin\ avain\ -\ arvo}{suurin\ avain\ -\ pienin\ avain}$ . Mikäli sarake ei ole aritmeettinen tai arvoa ei tiedetä käytetään vakiona arvoa 1/3.

```
sarake\ IN\ (lista\ arvoja) F = koko(lista) \times (sarake = arvo)
```

### 5 Alikyselyt

Kyselyn predikaatin operandin ollessa toinen kysely puhutaan alikyselystä. Alikyselyt suoritetaan..

Alikysely voi palauttaa yhden arvon tai listan arvoja riippuen sen operandista. Tutkitaan seuraavaa kyselyä:

```
SELECT nimi
FROM Kirjat
WHERE hinta =
(SELECT AVG(hinta)
FROM Kirjat)
```

Esimerkkikyselyssä alikysely palauttaa yhden arvon, AVG(hinta). Tämä arvo lisätään ylikyselyyn predikaatiksi niinkuin se olisi ollut osa ylempää kyselyä. Esimerkkitapauksessa keskiarvon ollessa 10 predikaatti on "hinta = 10".

Mikäli alikysely palauttaa useamman arvon, kuten seuraavassa tapauksessa:

```
SELECT nimi
FROM Kirjat
WHERE hinta IN (SELECT hinta
FROM Kirjat
WHERE genre = 'scifi')
```

käytetään alikyselyn palauttamaa listaa ylikyselyn predikaattina. Esimerkkikyselyn palauttaessa listan (5,15) vastaava ylikyselin predikaatti on "hinta IN (5,15).

## 6 Yhteenveto

### Lähteet

- [CAE+76] Chamberlin, D.D., M.M. Astrahan, K.P. Eswaran, P. P. Griffiths, R.A. Lorie, J. W. Mehl, P. Reisner ja B.W. Wade: SEQUEL 2: A Unified Approach to Data Definition, Manipulation, and Control. IBM Journal of Research and Development, 20(6):560-575, 1976, ISSN 0018-8646.
- [Cha98] Chaudhuri, Surajit: An overview of query optimization in relational systems. Teoksessa Proceedings of the seventeenth ACM SIGACT-SIGMOD-SIGART symposium on Principles of database systems, sivut 34–43. ACM, 1998.
- [Cod70] Codd, Edgar F: A relational model of data for large shared data banks. Communications of the ACM, 13(6):377–387, 1970.
- [DSRS01] Dalvi, Nilesh N, Sumit K Sanghai, Prasan Roy ja S Sudarshan:

  Pipelining in multi-query optimization. Teoksessa Proceedings of
  the twentieth ACM SIGMOD-SIGACT-SIGART symposium on
  Principles of database systems, sivut 59–70. ACM, 2001.
- [IK91] Ioannidis, Yannis E ja Younkyung Cha Kang: Left-deep vs. bushy trees: An analysis of strategy spaces and its implications for query optimization. Teoksessa ACM SIGMOD Record, nide 20, sivut 168–177. ACM, 1991.
- [Ioa96] Ioannidis, Yannis E: *Query optimization*. ACM Computing Surveys (CSUR), 28(1):121–123, 1996.
- [JK84] Jarke, Matthias ja Jurgen Koch: Query optimization in database systems. ACM Computing surveys (CsUR), 16(2):111–152, 1984.

- [Loh88] Lohman, Guy M: Grammar-like functional rules for representing query optimization alternatives, nide 17. ACM, 1988.
- [MCS88] Mannino, Michael V, Paicheng Chu ja Thomas Sager: Statistical profile estimation in database systems. ACM Computing Surveys (CSUR), 20(3):191–221, 1988.
- [MJ12] Mahajan, S.M. ja V.P. Jadhav: An analysis of execution plans in query optimization. Teoksessa Communication, Information Computing Technology (ICCICT), 2012 International Conference on, sivut 1–5, 2012.
- [MKR12] Mor, Jyoti, Indu Kashyap ja RK Rathy: Analysis of Query Optimization Techniques in Databases. International Journal, 47, 2012.
- [OL90] Ono, Kiyoshi ja Guy M Lohman: Measuring the complexity of join enumeration in query optimization. Teoksessa Proceedings of the 16th International Conference on Very Large Data Bases, sivut 314–325. Morgan Kaufmann Publishers Inc., 1990.
- [Ora05] Oracle: Understanding Shared Pool Memory Structures, syyskuu 2005. http://www.oracle.com/technetwork/database/focus-areas/manageability/ps-s003-274003-106-1-fin-v2-128827.pdf.
- [Ora09] Oracle: Oracle Database Online Documentation 11g Release 1, 2009. http://docs.oracle.com/cd/B28359\_01/server.111/b28318/sqlplsql.htm.

- [Ora13] Oracle: MySQL 5.0 Reference Manual, 2013. http://docs.oracle.com/cd/E17952\_01/refman-5.0-en/controlling-optimizer.html.
- [PHH92] Pirahesh, Hamid, Joseph M Hellerstein ja Waqar Hasan: Extensible/rule based query rewrite optimization in Starburst. Teoksessa International Conference on Management of Data: Proceedings of the 1992 ACM SIGMOD international conference on Management of data, nide 2, sivut 39–48, 1992.
- [RG03] Ramakrishnan, R. ja J. Gehrke: Database Management Systems. McGraw-Hill international editions: Computer science series. McGraw-Hill Education, 2003, ISBN 9780072465631. http://books.google.fi/books?id=JSVhe-WLGZOC.
- [SAC+79] Selinger, P Griffiths, Morton M Astrahan, Donald D Chamberlin, Raymond A Lorie ja Thomas G Price: Access path selection in a relational database management system. Teoksessa Proceedings of the 1979 ACM SIGMOD international conference on Management of data, sivut 23–34. ACM, 1979.
- [TF82] Teorey, Toby J ja James P Fry: Design of database structures.

  Prentice Hall Professional Technical Reference, 1982.