

HELSINGIN YLIOPISTO — HELSINGFORS UNIVERSITET — UNIVERSITY OF HELSINKI

Tiedekunta — Fakultet — Faculty		Laitos — Institution –	- Department			
		I				
${\bf Matema attis-luon non tiete ellinen}$		Tietojenkäsittelytieteen laitos				
Tekijä — Författare — Author						
Olli Rissanen						
Työn nimi — Arbetets titel — Title						
Tietokantakyselyjen optimointi relaatiotietokannassa						
Oppiaine — Läroämne — Subject						
Tietojenkäsittelytiede						
Työn laji — Arbetets art — Level	Aika — Datum — Mo	nth and year	Sivumäärä — Sidoantal — Number of pages			
Kandidaatintutkielma	4. toukokuuta 20	013	26			
Tiivistelmä — Referat — Abstract						

Tietokantakyselyn optimointi on prosessi, jossa tietokannan hallintajärjestelmän sisältämä kyselyn optimoija määrittää suorituskykyisimmän tavan kyselyn suorittamiseen. Suorituskykyisimmän suoritustavan löytämiseksi optimoija etsii joukon mahdollisia suoritustapoja, arvioi niiden suorittamiseen kuluvan kustannuksen ja valitsee niistä tehokkaimman. Kyselyn optimointi on NP-täydellinen ongelma, jossa mahdollisten suoritustapojen joukko voi kasvaa erittäin suureksi. Tutkielmassa tutustumme keskeisiin optimoinnin osa-alueisiin relaatiotietokantojen hallintajärjestelmien osalta sekä optimoinnin vaikutukseen kyselyjen suorituskyvyssä. Esittelemme tietokantakyselyn prosessoinnin ja optimoinnin kokonaisuudessaan yleisellä tasolla. Tarkastelemme vaihtoehtoisia tapoja mahdollisten suoritustapojen joukon luomiseen, kuten heuristiikkoja hyödyntävän dynaamisen algoritmin. Lisäksi tutkimme tilastotiedon käyttöä suoritustapojen kustannusarvioinnissa parhaan suoritustavan valitsemiseksi.

ACM Computing Classification System (CCS):

Information systems \rightarrow Query optimization

Theory of computation → Database query processing and optimization (theory)

Avainsanat — Nyckelord — Keywords

Tietokantakysely, optimointi, relaatiotietokanta

Säilytyspaikka — Förvaringsställe — Where deposited

 ${\it Muita\ tietoja--\"Ovriga\ uppgifter---Additional\ information}$

Sisältö

1	Joh	danto	3	
2	Opt	timoinnin perusteet	4	
	2.1	Relaatiomalli	4	
	2.2	Relaatioalgebra	5	
	2.3	Optimoinnin tavoite	6	
	2.4	Optimoinnin historia	7	
3	Tie	tokantakyselyn prosessointi	7	
	3.1	Kyselyn jäsentäminen	8	
	3.2	Kyselyn optimointi	9	
	3.3	Kyselyn suorittaminen	9	
4	Kys	selysuunnitelmien tuottaminen	9	
	4.1	Kyselysuunnitelma	10	
	4.2	Hakualgoritmit	11	
		4.2.1 Dynaamiset algoritmit	12	
		4.2.2 Muut algoritmit	13	
		4.2.3 Algoritmien heuristiikat	14	
	4.3	Alikyselyt	16	
5	Kyselysuunnitelmien kustannusarviointi			
	5.1	Systeemitauluston tilastotieto	17	
	5.2	Tulosjoukon koon arviointi	18	
6	Yht	teenveto	20	
Lä	ihtee	et	22	

1 Johdanto

Tallennettavan tiedon määrä kasvaa jatkuvasti, ja tämä johtaa tietokantojen työtaakan kasvamiseen. Jotta tiedosta saadaan mahdollisimman paljon irti, tarvitaan tiedon hallitsemiseen yhä tehokkaampia työkaluja. Optimoimalla tietokantakyselyjen suoritusta voidaan vaikuttaa suoritettujen operaatioiden määrään sekä muistialueen kokoon ja siten vähentää tietokannan vasteaikaa sekä resurssien käyttöä [MKR12]. Tutkielman tavoitteena on tutustuttaa lukija kyselyn optimointiin yleisellä tasolla sekä sen keskeisiin ongelmiin.

Tietokantaa käytetään tietokannan hallintajärjestelmällä, joka on kokoelma ohjelmia tiedon tallentamiseen, muokkaamiseen, analysoimiseen ja keräämiseen tietokannasta. Hallintajärjestelmää käytetään kyselykielellä, joista esimerkiksi SQL [CAE+76] on suunniteltu relaatiotietokantojen hallintajärjestelmille. Hallintajärjestelmän vastuulla on kyselyn muuttaminen tietokannan ymmärtämään muotoon säilyttäen kyselyn alkuperäinen tarkoitus.

Kyselyn optimointi on toteutettu automaattisena toimenpiteenä hallintojärjestelmän sisältämässä kyselyn optimoijassa, ja kaikista hallintajärjestelmän komponenteista optimoijalla on suurin merkitys tietokannan suorituskykyyn [MKR12]. Jokainen optimoija on osittain erilainen kokonaisuus komponentteja, jotka kuitenkin pohjautuvat samoihin yleisiin malleihin. Kyselyn optimoijan tavoitteena on minimoida itse optimointiin käytetty aika ja maksimoida optimoinnista saatu hyöty [JK84].

Optimoija toimii arvioimalla osajoukon kaikista tavoista kyselyn suorittamiseen ja valitsemalla niistä tehokkaimman [SAC⁺79]. Suoritustapaa kutsutaan kyselysuunnitelmaksi, ja se sisältää sarjan tietokannan relaatioihin kohdistuvia algebrallisia operaatioita, jotka tuottavat tulokseksi halutun vastauksen. Tietokantakyselyä vastaavia kyselysuunnitelmia on useita, sillä kysely voidaan usein esittää monena algebrallisesti toisiaan vastaavana esityksenä [JK84]. Algebrallista operaatiota kohden voi myös löytyä useita toteutuksia, kuten join-operaatiota toteuttavat merge join, hash join ja nested loop join. Kyselysuunnitelma sisältää operaatioiden lisäksi tiedon ne toteuttavista algoritmeista. Saman kyselyn sisältämät mahdolliset kyselysuunnitelmat voivat olla suorituskyvyltään jopa eri suuruusluokassa [Ioa96, Ora13].

Kyselyn optimointi on NP-täydellinen ongelma [IK84], jossa hakualue voi nousta erittäin suureksi. Haasteeksi nousee kyselysuunnitelmien hakeminen ja niiden suorituskyvyn ennustaminen. Kaikkien mahdollisten kyselysuunnitelmien arvioiminen on usein liian hidasta, joten optimoijan tulee valita pienin mahdollinen hakualue joka pitää sisällään halvimmat suunnitelmat [Cha98]. Suorituskyvyn ennustamisen ja hakualueen rajauksen lisäksi optimoija tarvitsee tehokkaan algoritmin koko hakualueen läpikäymiseen. On epärealistista odottaa kyselyn optimoijan aina löytävän parhaan kyselysuunnitelman, ja onkin tärkeämpää välttää huonoimpia suunnitelmia ja löytää hyvä suunnitelma [RG03].

Luvussa 2 perehdytään optimoijan keskeisiin esitietoihin esittelemällä relaatiomalli ja tutustumalla relaatioalgebran operaatioihin. Lisäksi luvussa esitetään optimoijan tavoitteet, mitattavat resurssit sekä annetaan lyhyt katsaus optimoinnin historiaan. Luku 3 tiivistää tietokantakyselyn prosessoinnin hallintajärjestelmän sisällä ja esittelee optimoijan toiminnan pääpiirteittäin kyselyn prosessoinnissa. Kyselysuunnitelman tuottamiseen syvennytään tarkemmin luvussa 4, jossa käsitellään kyselysuunnitelman rakennetta, niiden tuottamiseen käytettäviä algoritmeja sekä heuristiikkoja epäoptimaalisten kyselysuunnitelmien karsimiseen. Kyselysuunnitelmien kustannusarviointi ja siihen liittyvä tilastotiedon käyttö esitellään luvussa 5.

2 Optimoinnin perusteet

Tässä luvussa käydään läpi relaatiomallin käsite sekä relaatioalgebran operaatiot, jotka ovat optimoinnin keskeisimmät esitiedot. Lisäksi luvussa tutustutaan tarkemmin optimoinnin tavoitteisiin ja sen vaikutuksenalaisiin resursseihin, sekä annetaan lyhyt katsaus optimoinnin historiaan.

2.1 Relaatiomalli

Relaatiotietokanta on relaatiomalliin [Cod70] perustuva tietokanta. Relaatiomallin keskeinen piirre on kaiken datan esittäminen n-paikkaisen karteesisen tulon osajoukkona, ja se tarjoaa deklaratiivisen menetelmän datan ja ky-

selyjen määrittämiseen. Relaatiomalli koostuu attribuuteista, monikoista ja relaatioista, jotka esitetään kuvassa 1. Matemaattisessa määritelmässä attribuutti on pari joka sisältää attribuutin nimen ja tyypin. Jokaiseen attribuuttiin liittyy sen arvojoukko. Monikko on järjestetty joukko attribuuttien arvoja. Relaatio koostuu otsakkeesta ja sisällöstä, jossa otsake on joukko attribuutteja ja sisältö on joukko monikkoja. Relaation otsake on myös jokaisen monikon otsake. Visuaalisessa esityksissä relaatio on taulukko ja monikko taulukon rivi.

Attribuutti

Monikko {

Relaatio

Kuva 1: Relaatiomalliin perustuva tietokanta [wik08].

2.2 Relaatioalgebra

Relaatioalgebra on relaatiomalliin pohjautuva joukko relaation käsittelyyn tarkoitettuja operaatioita, ja se muodostaa relaatiotietokantojen teoreettisen pohjan. Relaatioalgebran operandit ovat relaatioita, ja sillä on joukko-opin operaatioiden lisäksi omia operaatioita. Tarkastelemme seuraavaksi tärkeimpiä operaatioita.

Liitos (join) on operaatio muotoa $A \bowtie B$, jossa A ja B ovat relaatioita. Liitos tuottaa relaation, jonka attribuutit ovat relaatiodien attribuuttien yhdiste: Join $(rel_1, A \text{ op B}, rel_2) = [\text{EACH } r_1 \text{ IN } rel_1, \text{ EACH } r_2 \text{ IN } rel_2 : r_1.A \text{ op } r_2.B]$, jossa op on relaatioita vertaileva predikaatti ja rel_1 sekä rel_2 liitettävät relaatiot [JK84].

Valinta (selection) on muotoa $\sigma_{ehto}(A)$, jossa ehto on jokin loogisilla operaatioilla $=, \neq, \leq, \geq, \wedge, \vee$ vertailtavissa oleva ehto. Valinta tuottaa relaation, joka on joukko kaikista relaation monikoista joille pätee valinnan ehto.

Projektio (projection) on muotoa $\pi_{a_1,...a_n}(A)$, jossa $a_1,...a_n$ on joukko attribuuttien nimiä. Projektio poimii relaatiosta alijoukon joka sisältää annetut attribuutit.

2.3 Optimoinnin tavoite

Tietokantakyselyjen optimoinnilla viitataan tietokantakyselyn suorittamiseen mahdollisimman tehokkaasti. Optimoinnin tavoitteena on joko maksimoida suorituskyky annetuilla resursseilla tai minimodia resurssien käyttö. Jarke ja Koch määrittävät mitattaviksi resursseiksi suorittimen ja muistin käytön sekä kommunikointikustannukset [JK84]. Teorey ja Fry [TF82] huomasivat optimoijan vaikuttavan suorittimen palveluaikaan (service time), suorittimen jonotusaikaan, I/O:n palveluaikaan, I/O:n jonotusaikaan ja lukittumisen viiveeseen. Osa tutkimuksista, kuten Kooi:n väitöskirja [Koo80] kuitenkin sivuuttavat suorittimen käytön kokonaan.

Muistin käyttö jakautuu tallennuskustannukseen sekä ulkomuistiin pääsyn kustannukseen. Tallennuskustannuksella tarkoitetaan ulkomuistin sekä puskurimuistin käyttöä, ja se tulee aiheelliseksi kun muistin käyttö aiheutuu pullonkaulaksi. Kommunikointikustannukset käsittävät tiedon viennin tallennuspaikasta laskentapaikkaan ja edelleen tulosten esityspaikkaan. Ne jakautuvat kommunikaatioväylän käyttökustannukseen ja tiedonsiirrosta aiheutuvaan suorittamisen viiveeseen.

Resurssin merkitys riippuu tietokantatyypistä. Jarke ja Koch erittelivät hajautetuissa tietokannoissa kommunikointikustannukset hallitseviksi kustannuksiksi sekä paikallisissa tietokannoissa kaikki resurssit samanarvoisiksi. Jarken ja Kochin mukaan keskitetyissä tietokannoissa ulkomuistiin pääsyn kustannus ja prosessorin käyttö ovat oleellisia. Tässä tutkielmassa keskitymme erityisesti keskitettyjen tietokantojen optimointiin.

2.4 Optimoinnin historia

Relaatiomallin myötä optimoinnista tuli osa järjestelmän toiminnallisuutta, sillä se tarjosi deklaratiivisuutensa vuoksi useita tapoja toteuttaa kukin kysely. Ennen relaatiomallin käyttöä optimointi tehtiin käsin. Selinger et al. esittelivät System R-hallintajärjestelmän OPTIMIZER-komponentin [SAC+79], joka on ensimmäisiä relaatiomalliin pohjautuvia kyselyn optimoijia. OPTI-MIZER esitteli dynaamisen hakualgoritmin kyselysuunnitelmien luomiseen, ja se on käytössä hieman muunneltuna käytännössä kaikissa kaupallisissa järjestelmissä [Ioa96].

3 Tietokantakyselyn prosessointi

Tietokannan hallintajärjestelmän suorittama SQL-kyselyn prosessointi sisältää useita vaiheita. Kuva 2 esittää kyselyn optimointikerroksen ja suorituskerroksen hallintajärjestelmän sisällä. Alempana analysoimme komponenttien toimintaa tarkemmin.

Kyselyn jäsentäjä

Jäsennetty kysely

Kyselyn optimoija

Kyselysuunnitelman kustannusarvioija

Kyselysuunnitelman kustannusarvioija

Kyselysuunnitelman kustannusarvioija

Kyselysuunnitelman kustannusarvioija

Kuva 2: Kyselyn jäsentäminen, optimointi ja suoritus [RG03].

3.1 Kyselyn jäsentäminen

Kyselyn prosessointi alkaa kyselyn jäsentäjän suorittamalla kyselyn syntaksin validoinnilla [SAC+79]. Syntaksin validoinnissa jäsentäjä tarkastaa kyselyn lauseopin oikeellisuuden. Osa hallintajärjestelmistä, kuten Oracle 11g, validoi myös samalla semantiikan oikeellisuuden [Ora09]. Semantiikan validoinnissa tarkastetaan objektien aitous, kyselyn yksiselitteisyys, oikeus haettavaan tietoon ja muuttujien tyypin sopivuus sarakkeiden tyyppeihin. Useat hallintajärjestelmät myös tallentavat kyselyt validoinnin jälkeen, jotta samaa kyselyä ei tarvitse jäsentää ja optimoida uudelleen. Yksi esimerkki kyselyjä tallentavasta hallintajärjestelmästä on Oracle Database, jossa tallennuspaikkaa kutsutaan nimellä Shared Pool [Ora05].

Seuraavaksi jäsentäjä jakaa kyselyn lohkoihin (block) siten, että yhdessä lohkossa on täsmälleen yksi SELECT-lause, yksi FROM-lause ja korkeintaan yksi WHERE-, GROUP BY- ja HAVING-lause [RG03]. Kyselyn mahdollisesti sisältämät alikyselyt muodostavat kukin oman lohkonsa. Alikyselyitä tarkastellaan luvussa 4.3.

Jokainen lohko jäsennetään puuksi, joka on kyselyn algebrallinen esitysmuoto [MJ12]. Puun solmu sisältää yhden operaation kyselyn suorittamiseksi, ja sillä on nolla tai useampi alisolmua joiden ulostuloa (output) käytetään sen syötteenä. Esimerkiksi join-operaatiossa solmulla on kaksi alisolmua, joille toteutetaan join-operaatio ja sort-operaatiolla on yksi alisolmu joka järjestetään. Lehtisolmut ovat solmuja jotka suorittavat hakuja (scan) levyltä ja palauttavat saadut tulokset. Puu suoritetaan lehtisolmuista juureen.

Tämän jälkeen monimutkaiset kyselyt uudelleenkirjoitetaan (rewrite) soveltamalla niihin muutossääntöjä [Ioa96]. Pirahesh et al. tutkivat uudelleenkirjotusta Starburst-hallintajärjestelmän osalta artikkelissa [PHH92]. He määrittivät uudelleenkirjoituksen tavoitteiksi tehdä kyselyistä mahdollisimman deklaratiivisia ja suorittaa luonnollisia heuristiikkoja. Yksi heuristiikka on operaatioiden siirtäminen suoritettavaksi mahdollisimman aikaisessa vaiheessa, kuten tietokantataulun lukemisen aikana.

3.2 Kyselyn optimointi

Kun kysely on jäsennetty ja mahdollisesti uudelleenkirjoitettu, lähetetään se kyselyn optimoijalle. Kyselyn optimoija hakee tietokannan systeemitaulustoon tallennettua tilastotietoa kyselyyn liittyvistä relaatioista ja relaatioihin liittyvistä saantipoluista (access path). Tilastotietoa käytetään kyselyn suorituskyvyn arviointiin. Saantipolku on menetelmä jolla taulurivit haetaan taulusta, ja se muodostuu joko tiedoston lukemisesta tai indiksien käytöstä. Selinger et. al. tutkivat kattavasti saantipolkujen kustannusarviointia artikkelissaan [SAC+79].

Mikäli kyselyn semantiikkaa ei ole vielä tarkastettu, tarkastaa optimoija kyselyn semantiikan oikeellisuuden ja kyselyn tyyppien sopivuuden sarakkeisiin ja operaatioihin systeemitaulun tiedon pohjalta. Optimoija määrittää lohkojen suoritusjärjestyksen ja käy läpi saantipolut jokaisen lohkon FROM-lauseen relaatioiden lukemiseen. Mikäli lohkossa on useampi relaatio, arvioi optimoija join-operaation järjestyksen ja suoritustapojen suorituskyvyt ja valitsee tehokkaimman algoritmin operaatioiden suorittamiseen. Optimoija valitsee jokaiselle lohkolle vähiten resursseja käyttävän saantipolun ja rakentaa niistä kyselysuunnitelman $[SAC^+79]$.

3.3 Kyselyn suorittaminen

Seuraavassa vaiheessa kysely suoritetaan käyttämällä optimoijan tuottamaa kyselysuunnitelmaa. Suorittamisessa kyselysuunnitelma muutetaan suoritettavaksi konekieleksi ja kyselyn lähteen mukaan joko suoritetaan tai tallennetaan muistiin myöhempää suorittamista varten.

4 Kyselysuunnitelmien tuottaminen

Kyselyn optimoijan tulee tuottaa mahdollisimman suorituskykyisen kyselysuunnitelman sisältämä joukko käyttämättä tuottamiseen liikaa resursseja. Tässä luvussa perehdymme ensiks kyselysuunnitelman rakenteeseen. Tämän jälkeen tutkimme algoritmeja kyselysuunnitelmien joukon luomiseen,

sekä heuristiikkoja epäoptimaalisten kyselysuunnitelmien karsimiseen. Luvun lopuksi tutkimme alikyselyjen suorittamista.

4.1 Kyselysuunnitelma

Kyselysuunnitelma koostuu laajennetusta relaatioalgebrapuusta, jossa jokainen solmu kuvaa algebrallista operaatiota. Solmuun on liitetty tieto käytettävästä hakumetodista tiedon hakemiseen taulusta ja suoritusmetodista operaation suoritukseen. Kyselysuunnitelma sisältää kaikki tiedot jotka hallintajärjestelmä tarvitsee halutun tiedon hakemiseen tietokannasta. Tutkitaan seuraavaa SQL-kyselyä:

```
SELECT K.nimi
```

FROM Kirjat K, Teokset T

WHERE K.tid = T.tid AND K.kid = 5 AND T.arvosana > 3

Kysely voidaan tulkita relaatioalgebrassa seuraavasti:


```
\pi_{nimi}(\sigma_{kid=5 \land arvosana>3}(Kirjat \bowtie_{tid=tid} Teokset))
```

Kysely voidaan suorittaa esimerkiksi käyttäen join-operaatiossa nested loop join-algoritmia, jonka jälkeen jokaiselle riville suoritetaan valinta ja projektio. Kyselyä vastaava esimerkkikyselysuunnitelma esitetään kuvassa 3.

Join-operaatiossa voidaan käyttää hyväksi putkitusta (pipelining) [DSRS01], jossa operandi putkitetaan suorituksen aikana toiseen operaatioon ilman väliaikaista taulua tuloksen tallentamiseen, lennossa. Ilman putkitusta väliaikaiset tulokset tulee tallentaa väliaikaiseen muuttujaan. Putkitusta käytetään usein peräkkäisten join-operaatioiden toteuttamiseen, jolloin jokainen operaation palauttama operandi voidaan syöttää seuraavan operaation parametriksi. Putkitusta voidaan käyttää operaation suorittavan algoritmin salliessa sen.

Usein tehokkaampi tapa kyselyn suorittamiseen on suorittaa valinnat mahdollisimman aikaisessa vaiheessa [RG03]. Esimerkkikyselyssä tauluille suoritetaan kullekin valinta erikseen, joten suorittamalla ne ennen join-operaatiota

Kuva 3: Kyselysuunnitelma esimerkkikyselylle.




voidaan vähentää yhdistettävien alkioiden määrää. Tehokkaampi kyselysuunnitelma aikaisilla valinnoilla, tallentaen valinnat väliaikaismuuttujiin T1 ja T2, esitetään kuvassa 4. Edelleen tehokkaampi tapa olisi välikaikaiseen muuttujaan tallentamisen sijaan putkittaa valinta-operaatiosta alkiot suoraan join-operaatioon.

4.2 Hakualgoritmit

Kyselyn optimoija tarvitsee tehokkaan algoritmin mahdollisten kyselysuunnitelmien luomiseen. Jarke ja Koch määrittelevät artikkelissaan [JK84] kaksi tapaa kyselysuunnitelman valintaan. Ensimmäisessä tavassa arvioidaan jokaisen erillisen kyselysuunnitelman kustannus, jolloin hyvä suunnitelma löydetään mutta optimointiin kulunut aika on suuri. Toisessa tavassa kustannus lasketaan inkrementaalisesti niiden rakentamisen aikana, ja suorituskyvyltään huonoksi havaitut kyselysuunnitelmat karsitaan pois. Selinger et al. esittelemä dynaaminen algoritmi [SAC+79] on toisen tavan laajennus, jossa algoritmi arvioi operaation ja sen mahdolliset vaikutukset seuraaviin operaatioihin kerrallaan.

Kuva 4: Suorituskykyisempi kyselysuunnitelma esimerkkikyselylle.



Kyselysuunnitelmat sisältävä hakualue voi kasvaa erittäin suureksi kyselyn ollessa laaja. Useat optimoijat käyttävät heuristiikkoja, kuten valinnan suorittamista mahdollisimman aikaisin tai vain tietynlaista join-operaatioiden järjestyksen hyväksymistä, pienentääkseen kyselysuunnitelmien määrää. Tavoitteena on pitää hakualue mahdollisimman pienenä, sisältäen kuitenkin optimaalisen suunnitelman [JK84]. Luvussa 4.2.1 tutustutaan tarkemmin dynaamisiin algoritmeihin sekä luvussa 4.2.2 vaihtoehtoisiin algoritmeihin hakualueen läpikäymiseen, kuten sääntöihin perustuvaan Starburst-hallintajärjestelmälle kehitettyyn algoritmiin [Loh88]. Lopuksi luvussa 4.2.3 käsitellään yleisiä optimoijan käyttämiä heuristiikkoja.

4.2.1 Dynaamiset algoritmit

Selinger et al. System R:lle esittelemä algoritmi on dynaaminen karsiva ja tyhjentävä (exhaustive) hakualgoritmi. Dynaamista algoritmia pidetään standardina algoritmina optimoijalle, ja usean hallintajärjestelmän hakualgoritmi pohjautuu dynaamiseen algoritmiin sisältäen kuitenkin hieman variaatioita. Algoritmi rakentaa kaikki mahdolliset join-puut käyttämällä heuristiikkoja ja karsii alioptimaalisiksi tiedetyt puut. Selinger et al. esittelemän algoritmin

käyttämät heuristiikat ovat predikaattien ja valintojen suorittaminen mahdollisimman aikaisin ja niiden putkitus, karteesisten tulojen välttäminen sekä pelkästään vasemmalta syvien puiden käyttö join-operaation suorituksessa. Heuristiikkoja tutkitaan tarkemmin luvussa 4.2.3. Algoritmi huomioi join-operaation suorittamiseen vain nested loop join- ja merging scans-algoritmit, joiden Selinger et al. huomasivat lähes aina tuottavan optimaalisen tai lähes optimaalisen suorituskyvyn muille paitsi erittäin pienille relaatioille.

Dynaaminen algoritmi toimii käyden jokaiselle kyselyn relaatiolle läpi jokaisen saantipolun, käyttäen mahdollisia indeksejä sekä tiedoston lukua. Algoritmi arvioi saantipolut, ja valitsee relaatioille suorituskykyisimmän saantipolun. Algoritmi pyrkii valitsemaan järjestetyn tulosjoukon palauttavan saantipolun, ellei järjestämätön tulosjoukko ole tehokkaampi. Järjestetty tulosjoukko mahdollistaa järjestettyä operandia vaativan merging scans-algoritmin käytön join-operaation suorittamiseen. Seuraavaksi algoritmi käy läpi kaikki tavat relaatioiden liittämiseen käyttäen aiemmin saatuja saantipolkuja ja heuristiikkoja, sekä karsii epäoptimaalisiksi huomatut tavat. Algoritmi arvioi edellisen askeleen tuottamat kyselysuunnitelmat ja palauttaa suorituskykyisimmän, jota käytetään kyselyn suorittamiseen.

4.2.2 Muut algoritmit

Dynaamisten algoritmien kilpailijoita ovat satunnaistetut algoritmit, kuten Iterative Improvement [NSS86], jossa algoritmi pyrkii dynaamisten algoritmien kyselysuunnitelmien tuottamisen sijaan rakentamaan yhden mahdollisimman hyvän suunnitelman. Algoritmi käy satunnaisesti läpi verkon solmuja, jossa jokainen solmu kuvaa yhtä kyselysuunnitelmaa johon on liitetty sen kustannus. Iterative Improvement valitsee vain siirtoja alamäkeen, jossa kohdesolmun kustannus on pienempi kuin lähtösolmun, ja lopuksi palauttaa reitin varrelta löydetyn pienimmän kustannuksen sisältävän solmun.

Satunnaisten algoritmien lisäksi geneettiset algoritmit, kuten Bennet et al. esittelemä algoritmi [BFI91], ovat tutkimuksen kohteena. Geneettinen algoritmi koostuu kromosomeista, jotka ovat ratkaisuita ongelmaan ja vertailtavissa keskenään niiden kunnon (fitness) mukaan. Geneettinen algoritmi simuloi

biologista ilmiötä, jossa kromosomeja verrataan keskenään niiden kunnon mukaan ja niistä luodaan jälkeläinen joka perii vanhemmilta ominaisuuksia. Vertailu tapahtuu iteraatioissa, joissa heikommat kromosomit karsiutuvat pois ja suorituskykyisemmät jatkavat seuraavaan iteraatioon. Bennet et al. algoritmissa kromosomit ovat binääripuita, joiden solmuissa on tieto kunkin operaation kustannuksesta. Suorituskykyisimmät jälkeläiset selviytyvät jatkoon, ja lopputuloksena saadaan optimaalinen ratkaisu.


4.2.3 Algoritmien heuristiikat

Optimoija voi suorittaa usean peräkkäisen join-operaation liittämisen monella eri tavalla. Ono ja Lohman tutkivat join-operaation suorittamisjärjestysten vaikutusta tarkemmin artikkelissaan [OL90], ja huomasivat join-operaation järjestyksen olevan hallitseva kustannus kyselyn optimoinnissa.

Tutkitaan kyselyä $Kirjat \bowtie Teokset \bowtie Kirjailijat \bowtie Maat$. Vasemmalta syväksi (left-deep) puuksi kutsutaan tapaa liittää kyselyt seuraavasti: ((($Kirjat \bowtie Teokset$) $\bowtie Kirjailijat$) $\bowtie Maat$), jossa oikea lapsi on aina kantataulu. Lehtevässä puussa myös oikea lapsi voi olla join-operaation tulos: ((($Kirjat \bowtie Teokset$) $\bowtie (Kirjailijat \bowtie Maat)$ Kuva 5 havainnollistaa vasemmalta syvät ja lehtevät puut. Optimoijat käyttävät usein pelkästään vasemmalta syviä puita, sillä eri tapoja liittää join-operaatioita on join-operaatioiden määrän kasvaessa erittäin paljon. Käyttämällä vain vasemmalta syviä puita voidaan pienentää hakualuetta [IK91], ja vasemmalta syvät puut mahdollistavat putkituksen. Oikea lapsisolmu eli join-operaation sisempi taulu täytyy aina materialisoida, sillä se täytyy käydä läpi jokaiselle ulomman taulun eli vasemman lapsisolmun monikolle [RG03].

Ioannidis ja Cha Kang tutkivat artikkelissaan [IK91] left-deep puiden ja lehtevien (bushy) puiden suorituskykyeroja, ja huomasivat sekä lehtevien puiden että vasemmalta syvien puiden samanaikaisen käytön olevan helpompaa ja sen tuottavan parempia tuloksia kuin vain vasemmalta syvien puiden käytön. Lehtevä puu mahdollistaa suuremman joukon mahdollisia kyselysuunnitelmia, joten se usein sisältää vasemmalta syviin puihin verrattuna huonompia suunnitelmia mutta usein myös optimaalisen suunnitelman.

Kuva 5: Vasemmalta syvät ja lehtevät puut.



Yleinen optimoijien käyttämä heuristiikka on myös predikaattien suorittaminen samaan aikaan relaatioiden ensimmäisen haun yhteydessä. Predikaateista projektio pyritään suorittamaan suoraan muiden operaatioiden tulosjoukolle. Levy et al. esittelivät artikkelissaan [LMS94] tavan siirtää predikaatteja lohkojen välillä, jolloin predikaatit voidaan suorittaa yhä aiemmin ja siten vähentää väliaikaisen tulosjoukon kokoa. He myös esittelivät aritmeettisesti vertailtavissa olevien predikaattien lisäksi tavan siirtää negatiivisia predikaatteja, kuten NOT EXISTS ja EXCEPT. Predikaattien suorittaminen mahdollisimman aikaisin ei kuitenkaan aina tuota suorituskykyisintä tulosta. [RG03] Mikäli taulut on indeksoitu, voi valinta kadottaa tärkeät indeksit jolloin join-operaation suorittaminen hidastuu.

Tärkeä heuristiikka on lisäksi karteesisten tulojen välttäminen join-operaation suorituksessa mikäli kysely ei erityisesti vaadi niitä. Heuristiikkaa toteuttava algoritmi tuottaa join-operaation suoritukseen vain vaihtoehdot jotka eivät sisällä karteesista tuloa. Chaudhuri havaitsi artikkelissaan [Cha98] karteesisten tulojen välttämisen toisinaan johtavan huonompaan suorituskykyyn.

Laajennetuissa optimoijissa heuristiikkoja voidaan vaihtaa kyselykohtaisesti [Cha98], kuten toisinaan sallimalla lehtevien puiden läpikäyminen tai karteesisten tulojen käyttäminen. On kuitenkin erittäin vaikeaa määritellä heuristiikkojen vaikutukset etukäteen. Yksi ratkaisu ongelmaan on geneettisten algoritmien [BFI91] käyttö parhaiden heuristiikkojen määrittämiseen.

4.3 Alikyselyt

Kyselyn predikaatin operandin ollessa toinen kysely puhutaan alikyselystä. Won Kim esitteli strategian [Kim82], jossa alikysely suoritetaan ennen ulompaa kyselyä ja saatu tulos liitetään ulomman kyselyn predikaatiksi. Kim jakoi alikyselyt viiteen luokkaan niiden sisältämien predikaattien mukaan. Tutkimme seuraavaksi näistä viidestä luokasta kahta luokkaa, joissa alikysely ei sisällä join-operaatiota joka viittaa ulompaan kyselyyn. Tällaisessa tapauksessa alikysely voidaan suorittaa omana lohkonaan.

```
SELECT nimi
FROM Kirjat
WHERE hinta =
(SELECT AVG(hinta)
FROM Kirjat)
```

Esimerkkikyselyssä alikyselyn palauttama arvo lisätään ulompaan kyselyyn predikaatiksi niinkuin se olisi ollut osa ulompaa kyselyä. Esimerkkitapauksessa AVG(hinta) palauttaessa arvon 10 predikaatiksi saadaan "hinta = 10". Alikysely voi myös palauttaa joukon monikkoja, kuten seuraavassa tapauksessa:

```
SELECT nimi
FROM Kirjat
WHERE tid IS IN
(SELECT tid
FROM Teokset
WHERE arvosana > 3)
```

Tällöin ulompaan kyselyyn liitetään predikaatti "tid IS IN X", jossa X

on alikyselyn palauttama joukko monikoita. Mikäli alikysely sisältää joinoperaation joka viittaa ulompaan kyselyyn, joudutaan join-operaatio suorittamaan ennen alikyselyn suorittamista. Alikyselyn paluuarvo voidaan
kuitenkin edelleen liittää ulomman kyselyn predikaatiksi. Kim esitteli strategiat ulommasta kyselystä riippuvaisten alikyselyjen suorittamiseen kolmessa
seuraavassa luokassaan. Yhteistä näille kolmelle luokalle on joidenkin operaatioiden suorittaminen ennen itse alikyselyn suorittamista.

5 Kyselysuunnitelmien kustannusarviointi

Kyselysuunnitelmien kustannusarvioinnissa optimoijan tulee arvioida kyselysuunnitelmien operaatioiden suorittamiseen kuluva aika sekä niiden tulosjoukon koko. Kyselysuunnitelman kustannus on sen sisältämien operaatioiden kustannusten summa, ja operaatioiden kustannukseen vaikuttaa olennaisesti sen operandien koko. Yksittäisten operaatioiden kustannus arvioidaan käyttämällä systeemitaulustoon tallennettua tilastotietoa operandeihin liittyvistä tiedoista, kuten indekseistä ja koosta. Systeemitaulusto koostuu tauluista ja näkymistä (view), ja sisältää kaiken tiedon mitä tietokanta tietää itsestään.

Optimoija käyttää kustannusarvointiin joko heuristisia arvioita tai kustannusmallia (cost model) [JK84], joista tutkimme tarkemmin kustannusmallia. Kustannusmallissa optimoija arvioi jokaisen operaation kustannuksen ja tulosjoukon koon, sillä operaation tulosjoukko on usein seuraavan operaation parametri. Kustannusmallin tuottaman kustannusarvion perusteella voidaan valita paras kyselysuunnitelma. Luvussa 5.1 tutustutaan tarkemmin systeemitaulustoon tallennettavaan tilastotietoon, ja luvussa 5.2 käsitellään systeemitauluston tilastotiedon pohjalta tehtävää kyselysuunnitelman kustannusarviointia.

5.1 Systeemitauluston tilastotieto

Systeemitaulusto sisältää tietokannan tilastollisen profiilin. Tilastotiedon avulla pyritään arvioimaan predikaattien ja operaatioiden kustannuksia käyttämällä tilastotietoa niiden operandeista. Mannino et al. tutkivat kattavasti

tilastotiedon käyttöä kyselyn optimoinnissa artikkelissaan [MCS88]. Heidän mukaan tarkka tilastotiedon tallentaminen on tärkeää kyselyn optimoinnille, mutta liian täsmällinen tallentaminen aiheutuu rasitteeksi.

Artikkelissa tilastollinen profiili jaettiin neljään kategoriaan: (1) keskitietoihin kuten moodi, mediaani ja keskiarvo, (2) hajontaan kuten varianssi sekä pienin ja suurin arvo, (3) kokoon kuten kardinaliteetti ja eri arvojen lukumäärä sekä (4) frekvenssin jakaantumiseen kuten normaalius ja tasaisuus. Systeemitaulusto sisältää myös jokaisesta taulusta tiedot sen nimestä ja tiedoston nimestä, attribuuttien tyypeistä ja nimistä, indekseistä ja niiden nimistä ja hakuavaimista sekä yleisistä tiedoista kuten sivukoosta ja puskurimuistin koosta. Hallintajärjestelmät tyypillisesti tallentavat tilastotiedon systeemitaulustoon histogrammeihin [Cha98], joissa tieto jaetaan lohkoihin. Optimoija voi tällöin ladata muistiin vain kulloinkin relevantit lohkot.

Bruno et al. tarkastelivat tutkimuksessaan tilastotiedon laajentamista väliaikaisiin tuloksiin, ja he huomasivat ratkaisun tuottavan parempia kyselysuunnitelmia kuin pelkän tietokannan taulun tilastotiedon käytön [BC02]. Ilman tilastotiedon käyttöä väliaikaisissa tuloksissa voi virhe kustannusarvioinnissa edetä operaatiolta operaatiolle ja johtaa tehottoman suunnitelman valintaan. Bruno et al. esittämä ratkaisu tallentaa tilastotietoa operaatioista saatuihin tulosjoukkoihin. Koko tilastotiedon tallentaminen väliaikaisiin tuloksiin on kuitenkin liian hidasta, joten he esittelivät algoritmin joka valitsee verrattaen pienen osajoukon saatavilla olevasta tilastotiedosta tallennettavaksi väliaikaisiin tuloksiin.

5.2 Tulosjoukon koon arviointi

Predikaatin kustannus riippuu sen syötteen koosta ja järjestyksestä. Tutkitaan seuraavaa tapausta:

SELECT attribuuttit

FROM relaatiot

WHERE ehto $1 \land$ ehto $2 \land ... \land$ ehto n

Kyselyn palauttamien monikkojen maksimimäärä on relaatioiden karteesinen tulo. Jokainen WHERE-ehto harventaa monikkojen määrää. WHERE-ehdon vaikutusta tulosjoukon kokoon voidaan mallintaa lisäämällä jokaiseen ehtoon vähennyskerroin, joka on oletettu suhde lähtöjoukosta tulosjoukkoon vain kyseisen ehdon osalta. Tulosjoukon koko voidaan siten arvioida kertomalla maksimijoukko vähennyskertoimien tulolla [RG03].

WHERE-lauseen ehtojen kertoimia voidaan laskea hyödyntämällä systeemitaulustoon tallennettua tilastotietoa. Selinger et al. määrittävät artikkelissaan [SAC+79] laskukaavoja vähennyskertoimien laskemiseen. He myös määrittivät oletuskertoimet relaatioille, joille arvioinnin kannalta olennaista tilastotietoa ei ole saatavilla. Oletetaan seuraavat tiedot:

NKeys(I) = eri avainten lukumäärä indeksissä IF = vähennyskerroin

Tutkimme seuraavaksi kahta Selinger et al. määrittelemää laskukaavaa:

sarake = arvo

Tämän tyyppiselle ehdolle vähennyskerroin voidaan arvioida kaavalla $F=\frac{1}{NKeys(I)}$, jos sarakkeessa on indeksi kyseiselle relaatiolle. Ilman indeksiä kyselyn optimoija käyttää kiinteää arvoa vähennyskertoimen arvioimiseen, joka esimerkiksi System R-relaatiotietokantaohjelmassa on 1/10.

sarake1 = sarake2

Tässä tapauksessa voidaan vähennyskerroin arvioida käyttäen kaavaa $F=\frac{1}{MAX(NKeys(I1),NKeys(I2))}$ jos kummassakin sarakkeessa on indeksi. Lisäksi oletetaan, että jokaisesta pienemmän indeksin arvoa vastaa arvo toisesta indeksistä. Mikäli vain toisessa sarakkeessa on indeksi, voidaan kustannus laskea aiemmalla kaavalla käyttäen indeksin omaavaa saraketta. Mikäli kummassakaan sarakkeessa ei ole indeksiä, arvioidaan arvoksi 1/10.

Join-predikaatin suorittamisessa merkittävää kustannusarvioinnin kannalta on sen suorittava algoritmi sekä join-predikaattien järjestys. Nested loop join- sekä merging scans-algoritmit ovat yleisesti käytettyjä, ja jälkimmäinen vaatii liitettävien relaatioiden olevan järjestyksessä liitettävien attribuut-

tien mukaan. Optimoijan tulee tällöin ottaa arvioinnissa huomioon relaation järjestämiseen kuluvat resurssit. Mahdolliset indeksit vaikuttavat myös olennaisesti algoritmien kustannuksiin.

6 Yhteenveto

Kyselyn optimoinnilla on tietokannan hallintajärjestelmän komponenteista suurin merkitys tietokannan suorituskykyyn. Optimoijan tehtävä on löytää mahdollisimman tehokas tapa suorittaa kysely. Optimoija käy läpi joukon kyselysuunnitelmia kyselyn suorittamiseen, arvioi niiden kustannuksen tilastotiedon pohjalta ja valitsee niistä parhaan. Kustannus koostuu kyselysuunnitelman suorittamiseen käytetyistä resursseista.

Esittelimme kyselyn optimoijan sijainnin hallintajärjestelmän komponenteissa ja tietokantakyselyn prosessoinnin yleisellä tasolla. Kyselysuunnitelmien tuottamisessa kaikkien suunnitelmien läpikäyminen on usein liian hidasta, joten huomioitavien kyselysuunnitelmien joukkoa pyritään rajaamaan. Tutkimme yleisiä hakualgoritmeja kyselysuunnitelmien joukon tuottamiseen, joista dynaamiset algoritmit käyttävät heuristiikkoja kyselysuunnitelmien joukon rajaamiseen. Heuristiikkojen käyttäminen ei ole triviaalia, sillä toisinaan paras kyselysuunnitelma karsitaan heuristiikan takia.

Kyselysuunnitelmien kustannusarviossa keskeinen ongelma on tilastotiedon optimaalinen tallentaminen. Liian tarkka tilastotiedon tallentaminen rasittaa tietokannan käyttöä, mutta auttaa kyselysuunnitelmien optimoinnissa. Tilastotiedon käyttö väliaikaisten tulosten arviointiin on tärkeää, sillä ilman sen käyttöä arviointivirhe etenee operaatiolta operaatiolle ja voi johtaa tehottoman kyselysuunnitelman valitsemiseen.

Sivusimme muita hakualgoritmeja, kuten geneettistä algoritmia, vain pintapuolisesti. Myös alikyselyn suorittamiseen tutkimme vain kahta tapausta, ohittaen monimutkaisemmat alikyselyt. Jätimme tutkimatta suurimman osan tilastotiedon käytön teoriasta, esitellen aihetta yksinkertaisin esimerkein.

Optimoijan toiminta on suurimmaksi osaksi piilotettu tietokannan käyttäjältä, mutta useat hallintajärjestelmät mahdollistavat optimoijan ohjaamisen

vihjeillä (hint). Usein vihjeillä voi määrittää käytettäviä indeksejä, hakualueen syvyyttä sekä joissain tapauksessa myös kytkeä kyselysuunnitelmien karsinnan pois päältä. Indeksin määrittäminen manuaalisesti mahdollistaa optimoijan käyttävän vain yhtä saantipolkua relaatiolle, ja näin vähentää luotavien kyselysuunnitelmien määrää.

Kyselyn optimoinnin tutkimus on yhä laajamittaista. Viimeaikaiset tutkimukset käsittelevät grafiikkaprosessorin sekä rinnakkaisohjelmoinnin hyödyntämistä kyselyn optimoinnissa [HM12, WLMO11], mutta myös vaihtoehtoisia algoritmeja dynaamiselle algoritmille [SC11]. Muita tutkittavia alueita ovat koneoppimisen käyttö suorituskykyisten kyselysuunnitelmien tunnistamiseen [BBC $^+$ 12] sekä optimaalinen tilastotiedon käyttö [HILM09].

Lähteet

- [BBC⁺12] Borkar, Vinayak, Yingyi Bu, Michael J Carey, Joshua Rosen, Neoklis Polyzotis, Tyson Condie, Markus Weimer ja Raghu Ramakrishnan: *Declarative systems for large-scale machine learning*. Bulletin of the Technical Committee on Data Engineering, 35(2):24, 2012.
- [BC02] Bruno, Nicolas ja Surajit Chaudhuri: Exploiting statistics on query expressions for optimization. Teoksessa Proceedings of the 2002 ACM SIGMOD international conference on Management of data, SIGMOD '02, sivut 263–274, New York, NY, USA, 2002. ACM, ISBN 1-58113-497-5. http://doi.acm.org/10.1145/564691.564722.
- [BFI91] Bennett, Kristin, Michael C. Ferris ja Yannis E. Ioannidis: A Genetic Algorithm for Database Query Optimization. Teoksessa In Proceedings of the fourth International Conference on Genetic Algorithms, sivut 400–407. Morgan Kaufmann Publishers, 1991.
- [CAE+76] Chamberlin, D.D., M.M. Astrahan, K.P. Eswaran, P. P. Griffiths, R.A. Lorie, J. W. Mehl, P. Reisner ja B.W. Wade: SEQUEL 2: A Unified Approach to Data Definition, Manipulation, and Control. IBM Journal of Research and Development, 20(6):560–575, 1976, ISSN 0018-8646.
- [Cha98] Chaudhuri, Surajit: An overview of query optimization in relational systems. Teoksessa Proceedings of the seventeenth ACM SIGACT-SIGMOD-SIGART symposium on Principles of database systems, PODS '98, sivut 34–43, New York, NY, USA, 1998. ACM, ISBN 0-89791-996-3. http://doi.acm.org/10.1145/275487.275492.
- [Cod70] Codd, E. F.: A relational model of data for large shared data banks. Commun. ACM, 13(6):377-387, kesäkuu 1970, ISSN 0001-0782. http://doi.acm.org/10.1145/362384.362685.

- [DSRS01] Dalvi, Nilesh N., Sumit K. Sanghai, Prasan Roy ja S. Sudarshan: Pipelining in multi-query optimization. Teoksessa Proceedings of the twentieth ACM SIGMOD-SIGACT-SIGART symposium on Principles of database systems, PODS '01, sivut 59–70, New York, NY, USA, 2001. ACM, ISBN 1-58113-361-8. http://doi.acm.org/10.1145/375551.375561.
- [HILM09] Haas, Peter J, Ihab F Ilyas, Guy M Lohman ja Volker Markl: Discovering and exploiting statistical properties for query optimization in relational databases: A survey. Statistical Analysis and Data Mining, 1(4):223–250, 2009.
- [HM12] Heimel, Max ja Volker Markl: A First Step Towards GPU-assisted Query Optimization. Teoksessa The Third International Workshop on Accelerating Data Management Systems using Modern Processor and Storage Architectures, Istanbul, Turkey, sivut 1–12, 2012.
- [IK84] Ibaraki, Toshihide ja Tiko Kameda: On the optimal nesting order for computing N-relational joins. ACM Trans. Database Syst., 9(3):482–502, syyskuu 1984, ISSN 0362-5915. http://doi.acm.org/10.1145/1270.1498.
- [IK91] Ioannidis, Yannis E. ja Younkyung Cha Kang: Left-deep vs. bushy trees: an analysis of strategy spaces and its implications for query optimization. SIGMOD Rec., 20(2):168–177, huhtikuu 1991, ISSN 0163-5808. http://doi.acm.org/10.1145/119995. 115813.
- [Ioa96] Ioannidis, Yannis E.: Query optimization. ACM Comput. Surv., 28(1):121-123, maaliskuu 1996, ISSN 0360-0300. http://doi. acm.org/10.1145/234313.234367.
- [JK84] Jarke, Matthias ja Jurgen Koch: Query Optimization in Database Systems. ACM Comput. Surv., 16(2):111–152, kesäkuu 1984, ISSN 0360-0300. http://doi.acm.org/10.1145/356924. 356928.

- [Kim82] Kim, Won: On optimizing an SQL-like nested query. ACM Trans. Database Syst., 7(3):443-469, syyskuu 1982, ISSN 0362-5915. http://doi.acm.org/10.1145/319732.319745.
- [Koo80] Kooi, Robert Philip: The optimization of queries in relational databases. 1980. AAI8109596.
- [LMS94] Levy, Alon Y., Inderpal Singh Mumick ja Yehoshua Sagiv: Query Optimization by Predicate Move-Around. Teoksessa Proceedings of the 20th International Conference on Very Large Data Bases, VLDB '94, sivut 96–107, San Francisco, CA, USA, 1994. Morgan Kaufmann Publishers Inc., ISBN 1-55860-153-8. http://dl.acm.org/citation.cfm?id=645920.672839.
- [Loh88] Lohman, Guy M.: Grammar-like functional rules for representing query optimization alternatives. SIGMOD Rec., 17(3):18–27, kesäkuu 1988, ISSN 0163-5808. http://doi.acm.org/10.1145/971701.50204.
- [MCS88] Mannino, Michael V., Paicheng Chu ja Thomas Sager: Statistical profile estimation in database systems. ACM Comput. Surv., 20(3):191–221, syyskuu 1988, ISSN 0360-0300. http://doi.acm.org/10.1145/62061.62063.
- [MJ12] Mahajan, Sunita M ja Vaishali P Jadhav: An analysis of execution plans in query optimization. Teoksessa Communication, Information & Computing Technology (ICCICT), 2012 International Conference on, sivut 1–5. IEEE, 2012.
- [MKR12] Mor, Jyoti, Indu Kashyap ja R. K. Rathy: Article: Analysis of Query Optimization Techniques in Databases. International Journal of Computer Applications, 47(15):6–12, June 2012.
- [NSS86] Nahar, Surendra, Sartaj Sahni ja Eugene Shragowitz: Simulated annealing and combinatorial optimization. Teoksessa Proceedings of the 23rd ACM/IEEE Design Automation Conference, DAC '86, sivut 293–299, Piscataway, NJ, USA, 1986. IEEE Press,

- ISBN 0-8186-0702-5. http://dl.acm.org/citation.cfm?id=318013.318059.
- [OL90] Ono, Kiyoshi ja Guy M Lohman: Measuring the complexity of join enumeration in query optimization. Teoksessa Proceedings of the 16th International Conference on Very Large Data Bases, sivut 314–325. Morgan Kaufmann Publishers Inc., 1990.
- [Ora05] Oracle: Understanding Shared Pool Memory Structures, syyskuu 2005. http://www.oracle.com/technetwork/database/focus-areas/manageability/ps-s003-274003-106-1-fin-v2-128827.pdf, |1.4.2013|.
- [Ora09] Oracle: Oracle Database Online Documentation 11g Release 1, 2009. http://docs.oracle.com/cd/B28359_01/server.111/b28318/sqlplsql.htm, |1.4.2013|.
- [Ora13] Oracle: MySQL 5.0 Reference Manual, 2013. http://docs.oracle.com/cd/E17952_01/refman-5.0-en/controlling-optimizer.html, |1.4.2013|.
- [PHH92] Pirahesh, Hamid, Joseph M Hellerstein ja Waqar Hasan: Extensible/rule based query rewrite optimization in Starburst. Teoksessa International Conference on Management of Data: Proceedings of the 1992 ACM SIGMOD international conference on Management of data, nide 2, sivut 39–48, 1992.
- [RG03] Ramakrishnan, Raghu ja Johannes Gehrke: Database Management Systems. McGraw-Hill, Inc., New York, NY, USA, 3 painos, 2003, ISBN 0072465638, 9780072465631.
- [SAC+79] Selinger, P. Griffiths, M. M. Astrahan, D. D. Chamberlin, R. A. Lorie ja T. G. Price: Access path selection in a relational database management system. Teoksessa Proceedings of the 1979 ACM SIGMOD international conference on Management of data, SIGMOD '79, sivut 23-34, New York, NY, USA, 1979. ACM, ISBN 0-89791-001-X. http://doi.acm.org/10.1145/582095. 582099.

- [SC11] Sevinç, Ender ja Ahmet Coşar: An evolutionary genetic algorithm for optimization of distributed database queries. The Computer Journal, 54(5):717–725, 2011.
- [TF82] Teorey, Toby J. ja James P. Fry: Design of Database Structures. Prentice Hall Professional Technical Reference, 1982, ISBN 0132000970.
- [wik08] Relational database terminology, joulukuu 2008. https: //en.wikipedia.org/wiki/File:Relational_database_terms.svg, |1.4.2013|.
- [WLMO11] Wu, Sai, Feng Li, Sharad Mehrotra ja Beng Chin Ooi: Query optimization for massively parallel data processing. Teoksessa Proceedings of the 2nd ACM Symposium on Cloud Computing, SOCC '11, sivut 12:1–12:13, New York, NY, USA, 2011. ACM, ISBN 978-1-4503-0976-9. http://doi.acm.org/10.1145/2038916.2038928.